



Facultad de Ingeniería
Escuela de Ingeniería Informática

Impacto del diseño físico de bases de datos distribuidas en la eficiencia y el consumo energético bajo TPC-H

Martín Andrés Carrillo Salinas

Trabajo realizado para optar al título de
Ingeniero Civil Informático

Prof. Guía: **Ana Aguilera**
Prof. Correferente: **Marlene Goncalves**

Valparaíso, Julio 2026

Certificación


Certifico que he leído este documento y que, en mi opinión, es adecuado en ámbito y calidad como trabajo para optar al título de Ingeniero Civil Informático.

Ana Aguilera
Profesor Guía

Certifico que he leído este documento y que, en mi opinión, es adecuado en ámbito y calidad como trabajo para optar al título de Ingeniero Civil Informático.

Marlene Goncalves
Profesor Correferente

Certifico que he leído este documento y que, en mi opinión, es adecuado en ámbito y calidad como trabajo para optar al título de Ingeniero Civil Informático.



Enrique Canessa
Profesor Informante

Aprobado por la Escuela de Ingeniería Informática, Universidad de Valparaíso.

Declaración sobre el uso de herramientas de Inteligencia Artificial

Yo, **Martín Andrés Carrillo Salinas**, autor del trabajo “*Impacto del diseño físico de bases de datos distribuidas en la eficiencia y el consumo energético bajo TPC-H*”, declaro que el contenido de este documento es original y ha sido elaborado principalmente mediante mi propio esfuerzo intelectual, en conformidad con los principios de integridad académica exigidos por la universidad.

Declaro asimismo que se han utilizado herramientas de Inteligencia Artificial exclusivamente como apoyo en las siguientes tareas auxiliares: mejora y corrección ortográfica, coherencia redaccional y claridad en la explicación de contenidos; configuración de los motores de bases de datos; y escritura de los scripts de orquestación de consultas para garantizar su correcto funcionamiento. Estas herramientas no han sido empleadas para la generación autónoma de contribuciones sustantivas del trabajo, tales como el planteamiento del problema, el diseño metodológico, la implementación ni el análisis de resultados, los cuales corresponden íntegramente al autor.

Todo contenido asistido por IA ha sido revisado, validado y adaptado críticamente, garantizando su pertinencia, exactitud y originalidad. Asumo plena responsabilidad por el contenido final del documento.

Impacto del diseño físico de bases de datos distribuidas en la eficiencia y el consumo energético bajo TPC-H

Martín Andrés Carrillo Salinas^{a,*}, Ana Aguilera^a, Marlene Goncalves^a

^a*Escuela de Ingeniería Informática, Universidad de Valparaíso, Valparaíso, Chile*

Resumen

El crecimiento sostenido del volumen de datos y del consumo eléctrico de los centros de datos ha convertido la eficiencia energética en un criterio de diseño tan relevante como la latencia. Este trabajo presenta un estudio empírico que cuantifica el impacto de las decisiones de diseño físico —indexación y compresión— sobre el tiempo de ejecución y el consumo energético de consultas analíticas, comparando dos paradigmas de almacenamiento: el motor documental MongoDB y el data warehouse Apache Hive. La metodología consiste en un experimento factorial controlado de 3.520 ejecuciones que combina cuatro configuraciones de diseño físico, dos modalidades de despliegue (distribuido y centralizado) y las veintidós consultas del benchmark TPC-H, instrumentado a nivel de proceso mediante la herramienta Scaphandre sobre un clúster físico homogéneo de tres nodos. El análisis estadístico, basado en pruebas de Wilcoxon pareadas y correlaciones de Spearman, revela que la estrategia óptima depende del motor: la indexación reduce la energía mediana de MongoDB en un 98,4 %, mientras que la compresión columnar la reduce en un 50,3 % en Hive. Los resultados aportan directrices reproducibles para el diseño de arquitecturas de datos energéticamente sostenibles.

Palabras clave: diseño físico de bases de datos, consumo energético, bases de datos distribuidas, TPC-H, MongoDB, Apache Hive

*Contacto: Martín Andrés Carrillo Salinas (martin.carrillo@estudiantes.uv.cl)

Especificaciones del estudio

Tabla 1: Información general del estudio empírico y disponibilidad de recursos

Descripción	Detalle
Área temática	Bases de datos distribuidas; eficiencia energética del cómputo
Tipo de contribución	Metodología experimental reproducible de medición energética
Motores evaluados	MongoDB 8.0.17 (documental) y Apache Hive 3.1.3 sobre Hadoop 3.3.6
Carga de trabajo	Benchmark TPC-H, factor de escala 5 GB (22 consultas)
Instrumentación energética	Scaphandre 2.6.0 vía Intel RAPL (error <0,5 %, overhead <1 %)
Infraestructura	Clúster físico homogéneo de 3 nodos Intel Core i3-6100, 12 GB RAM, SSD 447 GB, Ubuntu 24.04.3 LTS
Diseño experimental	Factorial $4 \times 2 \times 2 \times 22 \times 10 = 3,520$ ejecuciones
Análisis estadístico	Wilcoxon pareado con corrección Holm–Bonferroni; correlación de Spearman ($\alpha = 0,05$)
Disponibilidad de recursos	Datos brutos y código en repositorios públicos (Anexo B)

1. Introducción

El volumen de datos generado por servicios en la nube, la inteligencia artificial y las plataformas distribuidas crece de forma sostenida, y con él la presión sobre la infraestructura que los almacena y procesa. Los sistemas de gestión de bases de datos (SGBD) se despliegan principalmente bajo dos paradigmas: el *centralizado*, donde los datos y el procesamiento residen en un único nodo, y el *distribuido*, que reparte la carga entre múltiples nodos para ganar escalabilidad horizontal, disponibilidad y tolerancia a fallos [1, 2]. Dentro de este panorama, MongoDB se ha consolidado como motor documental distribuido y Apache Hive como solución analítica de tipo *data warehouse* sobre Hadoop, representando dos paradigmas estructuralmente opuestos [3, 4]. Sobre ambos, el costo energético del procesamiento ha pasado a ser un factor de diseño de primer orden: según la Agencia Internacional de la Energía, los centros de datos consumieron del orden de 415 TWh en 2023, cifra que podría alcanzar 945 TWh hacia 2030, con una huella de carbono indirecta estimada en 180 millones de toneladas de CO₂ [5, 6].

1.1. Marco conceptual

La **energía** es la capacidad de un sistema para realizar trabajo y se mide en *joules* (J); la **potencia** es la rapidez con que se realiza ese trabajo y se mide en *vattios* (W), de modo que $P = E/t$. El **consumo energético** de un proceso corresponde a la integral de la potencia instantánea a lo largo de su ejecución, y es la magnitud central de este estudio [7]. El **benchmark TPC-H**, definido por el *Transaction Processing Performance Council*, es un estándar para sistemas de soporte a decisiones compuesto por 22 consultas analíticas *ad-hoc* sobre un esquema de 8 tablas que simula un sistema de ventas global [8]. La instrumentación energética se apoya en **Scaphandre**, una herramienta de código abierto que utiliza la interfaz *Intel RAPL* (Running Average Power Limit) para estimar el consumo a nivel de proceso con un error inferior al 0,5 % y un *overhead* menor al 1 % [9, 10, 11]. En cuanto a las tecnologías, MongoDB es un SGBD *NoSQL* documental que escala horizontalmente mediante *sharding*, mientras que Apache Hive

ejecuta consultas sobre HDFS empleando formatos columnares (ORC) y compresión [2, 12, 13]. El *diseño físico* de ambos abarca la indexación, la compresión y las estrategias de distribución (*sharding* o *bucketing*), cuya configuración determina el plan de ejecución y, por tanto, el costo en tiempo y energía [14]. Un **índice** es una estructura de datos auxiliar que almacena, de forma ordenada o mediante funciones *hash*, los valores de una o varias claves junto con punteros a la ubicación física de los registros correspondientes; su propósito es que el motor localice las filas que satisfacen un filtro o una unión sin recorrer la totalidad de los datos, lo que reduce el número de lecturas a costa de un mayor uso de almacenamiento y de un sobrecosto de mantenimiento en las operaciones de escritura. En MongoDB los índices se implementan como árboles B (*B-tree*) sobre los campos de los documentos, mientras que, como se detalla más adelante, Apache Hive 3.x prescinde de los índices relacionales clásicos y logra un efecto equivalente mediante el formato columnar, el *bucketing* y las estadísticas del optimizador. La **compresión** empleada en este estudio es **Snappy** (de Google), una técnica sin pérdida —que permite reconstruir exactamente los datos originales— de la familia de algoritmos LZ77, cuyo propósito es reducir el tamaño físico de los datos eliminando redundancia para que ocupen menos espacio en disco y requieran menos operaciones de entrada/salida en su lectura. Su funcionamiento consiste en recorrer el flujo de bytes buscando secuencias que ya aparecieron antes y sustituirlas por referencias hacia esa ocurrencia previa (una posición y una longitud), sin añadir una etapa de codificación entrópica; al operar directamente sobre bytes y omitir ese paso, prioriza la velocidad de compresión y descompresión por encima de la máxima reducción de tamaño. Esta característica la hace idónea para cargas analíticas, donde el menor volumen leído de disco compensa el sobrecosto de CPU de la descompresión siempre que este no supere el ahorro. Snappy se integra de forma nativa tanto en el motor de almacenamiento WiredTiger de MongoDB —donde comprime bloques de documentos BSON— como en el formato columnar ORC de Apache Hive —donde comprime cada *stripe* de columnas—, lo que permite contrastar el mismo algoritmo bajo dos organizaciones físicas distintas: orientada a filas en MongoDB y orientada a columnas en Hive.

1.2. Estado del arte

Una revisión sistemática basada en *Web of Science* y en el análisis de redes de citación seleccionó los catorce trabajos más relevantes sobre consumo energético en bases de datos. De su análisis se desprende que el benchmark más empleado es YCSB (6 de 14), seguido de TPC-H y TPC-DS (4 cada uno); que MongoDB se evalúa en 8 de los 14 estudios y Hive o Hadoop en 4; y, de forma crítica, que la medición a nivel de proceso con Scaphandre aparece en un solo trabajo, aplicado además sobre un único nodo sin clúster físico distribuido [15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27]. La síntesis comparativa completa de los catorce trabajos se incluye en el Anexo C. El antecedente más cercano es el de Karras et al. [28], único que combina MongoDB con TPC-H en entorno distribuido, aunque optimizando solo el tiempo de ejecución mediante un mediador con Apache Spark SQL y sin medir el consumo energético; la Tabla 2 sintetiza las diferencias con el presente estudio.

1.3. Definición del problema

Pese a la magnitud del problema energético, la comprensión empírica del impacto de las decisiones de diseño físico es todavía limitada, pues la literatura privilegia métricas de tiempo y emplea metodologías heterogéneas difíciles de comparar. De la revisión emergen cuatro vacíos metodológicos concretos: (i) ningún trabajo contrasta directamente el *sharding* hash de MongoDB frente al almacenamiento columnar ORC con *bucketing* de Hive bajo una misma carga

Tabla 2: Comparación entre Karras et al. (2023) y este estudio

Dimensión	Karras et al. (2023)	Este estudio
Motor(es)	MongoDB + Apache Spark SQL (mediador)	MongoDB y Apache Hive independientes
Métrica principal	Tiempo de ejecución promedio	Tiempo de ejecución y consumo energético (J)
Medición energética	Ninguna	Scaphandre 2.6.0 vía Intel RAPL (proceso, multinodo)
Modalidades de despliegue	Distribuido (MongoDB + Spark)	Centralizado y distribuido sobre el mismo hardware
Contraste cruzado entre motores	No	Sí (MongoDB frente a Hive)
Robustez estadística	Sin réplicas ni pruebas inferenciales	10 iteraciones; Wilcoxon y Spearman con Holm–Bonferroni

TPC-H; (ii) ningún estudio evalúa conjuntamente las modalidades distribuida y centralizada para ambos motores bajo un mismo diseño experimental, lo que impide aislar el costo energético de la coordinación entre nodos; (iii) solo uno de los catorce trabajos relevantes emplea instrumentación a nivel de proceso —y únicamente sobre un nodo aislado, sin clúster físico—; y (iv) la literatura no documenta infraestructuras físicas reproducibles [29]. El problema central es, por tanto, la ausencia de evidencia empírica integral que evalúe de forma conjunta el rendimiento y el consumo energético de SGBD distribuidos y centralizados, bajo configuraciones reproducibles y cargas estandarizadas.

1.4. Objetivos

Objetivo general. Analizar empíricamente el impacto del diseño físico de bases de datos en la eficiencia de ejecución y el consumo energético, para identificar configuraciones que optimicen el uso de recursos en entornos de almacenamiento distribuido y centralizado.

Objetivos específicos.

- O1. Comparar el consumo energético y el tiempo de ejecución de MongoDB 8.0.17 y Apache Hive 3.1.3 bajo las 22 consultas TPC-H, evaluando cuatro configuraciones de diseño físico en las modalidades distribuida y centralizada.
- O2. Cuantificar la viabilidad de Scaphandre como herramienta de medición energética a nivel de proceso en un clúster físico de tres nodos.
- O3. Evaluar el efecto individual y combinado de la indexación y la compresión Snappy sobre la energía y la latencia, identificando la configuración más eficiente por motor y modalidad.
- O4. Determinar los *trade-offs* entre el paradigma documental de MongoDB y el de *data warehouse* de Hive, y entre las modalidades de despliegue, respecto al consumo energético, para proponer directrices de arquitecturas de datos sostenibles.

2. Diseño de la solución

2.1. Modelamiento de la solución

La solución se articula en cuatro componentes: (1) un clúster físico homogéneo de tres nodos; (2) MongoDB con *sharding* hash en modalidad distribuida e instancia *standalone* en la centralizada, y Apache Hive sobre Hadoop con *bucketing* hash en la distribuida y nodo único en la centralizada; (3) el benchmark TPC-H con factor de escala 5 GB; y (4) la medición energética no intrusiva mediante Scaphandre sobre Intel RAPL. La equivalencia metodológica entre motores se garantiza aplicando el mismo criterio de partición hash sobre la clave principal, restringido a las seis tablas de mayor volumen, de modo que el *sharding* de MongoDB y el *bucketing* de Hive sean funcionalmente comparables.

2.2. Metodología de investigación

El trabajo adopta una metodología experimental cuantitativa estructurada en seis etapas: (1) investigación preliminar sobre NoSQL, *data warehousing*, consumo energético y *benchmarking*; (2) diseño del entorno experimental (arquitectura de MongoDB y del clúster Hadoop/Hive en ambas modalidades, definición de las cuatro configuraciones y de los parámetros TPC-H); (3) implementación del entorno sobre los tres nodos; (4) ejecución de las pruebas con diez repeticiones por consulta, *timeout* de tres horas y *cooldown* de 300 s entre iteraciones; (5) análisis de datos en Python; y (6) evaluación de resultados para determinar el mejor equilibrio entre rendimiento y eficiencia. El esquema metodológico global se presenta en el Anexo G (Figura G.1).

2.3. Técnicas de análisis

La energía total por consulta (J) se obtiene por integración trapezoidal de la serie de potencia muestreada por Scaphandre. Dado que los datos no siguen una distribución normal, las comparaciones entre configuraciones emplean la prueba de Wilcoxon pareada sobre las 22 consultas, con corrección Holm–Bonferroni para las seis comparaciones múltiples por motor ($\alpha = 0,05$). La relación entre tiempo y energía se cuantifica con el coeficiente de correlación de Spearman (ρ), y las configuraciones se ordenan mediante un *score* de victorias menos derrotas estadísticamente significativas. Las ejecuciones que exceden las tres horas se tratan como observaciones censuradas: se incluyen en el análisis descriptivo y se excluyen de las comparaciones pareadas.

2.4. Procesos de recolección, almacenamiento, análisis y visualización

En la **recolección**, Scaphandre 2.6.0 captura la potencia (W) a nivel de proceso en cada nodo vía Intel RAPL con un muestreo cada 2 s; en Hive, el *JobHistory Server* registra los tiempos por fase (MAP, SHUFFLE, REDUCE) y, en MongoDB, el *profiler* aporta los tiempos por *shard*. En el **almacenamiento**, los datos se guardan en archivos CSV estructurados por la tupla {motor, despliegue, configuración, consulta, iteración}, con columnas *row_type*, *iteration*, *elapsed_seconds* y *power_total_watts*, versionados en Git. En el **análisis**, mediante *pandas*, *numpy* y *scipy.stats*, se validan las columnas, se calcula la energía por integración trapezoidal y se marcan los *timeouts*. En la **visualización**, con *matplotlib* y *seaborn*, se generan barras en escala logarítmica, comparativos de medianas, diagramas de dispersión tiempo–energía, mapas de calor, gráficos radar y barras apiladas de participación por nodo.

3. Experimentos

3.1. Definición de variables

Las variables *independientes* son el motor SGBD (MongoDB o Apache Hive), la modalidad de despliegue (distribuida o centralizada) y la configuración de diseño físico (*baseline*, índices, compresión, índices+compresión); las variables *dependientes* son el consumo energético (J) y la latencia (s) por consulta; y como variables de *control* se fijan el entorno hardware (tres nodos idénticos) y el estado inicial del sistema (limpieza de cachés y reinicio del servicio antes de cada iteración). Las 22 consultas TPC-H se clasifican en 9 de tipo *I/O-bound* y 13 *CPU-bound*. La Tabla 3 resume las preguntas de investigación, las hipótesis y las métricas asociadas.

Tabla 3: Matriz de consistencia: preguntas de investigación, hipótesis y métricas

Pregunta de investigación	Hipótesis	Métricas clave
¿El despliegue distribuido reduce el tiempo frente al centralizado?	H1: El despliegue distribuido presentará tiempos menores que el centralizado en ambos motores, al paralelizar lectura y procesamiento.	Latencia (s); razón distribuido/centralizado
¿El despliegue centralizado consume menos energía que el distribuido?	H2: El despliegue centralizado consumirá menos energía, al eliminar la sobrecarga de coordinación entre nodos.	Energía total (J); razón centralizado/distribuido
¿El diseño físico mejora el rendimiento y reduce la energía?	H3: La configuración Índices+Compresión será la más eficiente, pero el grado de mejora diferirá entre MongoDB y Hive por sus diferencias estructurales.	Energía (J); latencia (s); % de reducción frente al <i>baseline</i>

3.2. Diseño arquitectónico

El experimento se ejecutó sobre un clúster físico homogéneo de tres nodos, cada uno con procesador Intel Core i3-6100 a 3,70 GHz, 12 GB de RAM DDR4 y disco SSD Kingston de 447 GB, interconectados por Ethernet de 100 Mbps con direcciones IP fijas y ejecutando Ubuntu 24.04.3 LTS. En la modalidad *distribuida*, MongoDB se configuró con *sharding* hash —el nodo *node1* alojó el *Config Server*, el enrutador *mongos* y uno de los tres *shards*, mientras *node2* y *node3* albergaron los restantes—, y Apache Hive se desplegó sobre un clúster HDFS de tres *DataNodes* con *bucketing* hash sobre la clave principal de cada tabla. En la modalidad *centralizada*, MongoDB operó como instancia *standalone* y Hadoop en modo pseudodistribuido de nodo único, sin fragmentación. El esquema del diseño de experimentos se presenta en el Anexo G (Figura G.2).

3.3. Implementación realizada

Sobre cada combinación motor–modalidad se implementaron las cuatro configuraciones de diseño físico de la Tabla 4, lo que totaliza 16 configuraciones experimentales. Cada una de las 3.520 ejecuciones siguió un protocolo idéntico: (1) reinicio en frío fuera de la ventana de medición —limpieza de cachés del sistema operativo y reinicio del servicio del motor, verificando el

cambio de PID—; (2) arranque de un muestreador paralelo que consulta las métricas de Scaphandre cada 2 s y acumula la potencia de los procesos del motor; (3) ejecución cronometrada de la consulta, con *timeout* de tres horas (10.800 s); y (4) cierre de la ventana de medición y cálculo de la energía por integración trapezoidal.

Tabla 4: Definición de las cuatro configuraciones de diseño físico por motor

Configuración	MongoDB 8.0.17	Apache Hive 3.1.3
1. Baseline	Sin índices ni compresión; escaneo completo de colección	Formato TextFile plano, sin <i>bucketing</i> ni compresión
2. Índices	Índices simples y compuestos sobre claves principales y foráneas	ORC + <i>bucketing</i> hash + ordenamiento + estadísticas del CBO
3. Compresión	Snappy a nivel de bloque sobre WiredTiger, sin índices	ORC + Snappy a nivel de <i>stripe</i> , sin <i>bucketing</i>
4. Índices + Compresión	Índices compuestos + Snappy sobre WiredTiger	ORC + <i>bucketing</i> + ordenamiento + Snappy + CBO

La configuración *Índices* requiere una precisión conceptual, sobre todo en Apache Hive. En MongoDB corresponde literalmente a índices B-tree simples y compuestos sobre las claves primarias y foráneas del esquema. En Hive, en cambio, no existe un equivalente directo: desde la versión 3.x se eliminó el soporte para los índices relacionales clásicos por considerarlos ineficientes frente a las capacidades nativas del formato columnar. Por ello, en Hive el rol funcional de la indexación —acelerar el filtrado, las uniones y el acceso selectivo a los datos— se materializa mediante la combinación de *bucketing* hash (que particiona físicamente las filas por clave y habilita uniones *map-side* sin fase de *shuffle*), el ordenamiento dentro de cada *bucket* y las estadísticas del optimizador basado en costos (CBO), que permiten al planificador podar datos y elegir el mejor plan de ejecución. Se clasifica esta configuración como *Índices* porque persigue el mismo objetivo que un índice tradicional —reducir el volumen de datos leído y el costo de las uniones— aunque a través de un mecanismo estructuralmente distinto y propio del paradigma columnar de Hive.

3.4. Casos de estudio y datasets

La carga de trabajo se generó con *TPC-H dbgen* a factor de escala 5 GB (SF=5), produciendo las 8 tablas del esquema; este factor se eligió tras descartar factores superiores (hasta SF=100) por las limitaciones de memoria del hardware. Los datos se cargaron en MongoDB como documentos BSON con referencias entre colecciones y en Hive como tablas gestionadas en HDFS sobre ORC. El conjunto de resultados experimentales —las medianas de potencia muestreadas y los tiempos— constituye un segundo *dataset*, respaldado en repositorios públicos (Anexo B). Los cuatro casos de estudio corresponden a las cuatro configuraciones de diseño físico de la Tabla 4.

4. Resultados

4.1. Análisis de resultados

Los resultados se organizan en tres niveles de creciente detalle: primero se reportan las tasas globales de finalización de las ejecuciones; a continuación, las medianas de tiempo y energía por

configuración y modalidad para cada motor (Tablas 5 y 6), que constituyen el resultado principal; y, por último, la interpretación estadística y el contraste de las hipótesis. El detalle exhaustivo por consulta —las figuras individuales de las 22 consultas TPC-H y las tablas estadísticas completas— se recoge en el Anexo G y en el Anexo E, mientras que la subsección *Visualización de resultados* describe su lectura.

La primera evidencia aparece en las tasas de finalización dentro del *timeout* de tres horas: MongoDB completó 119 de 176 ejecuciones (67,6 %), concentrándose los *timeouts* en las configuraciones *Baseline* y de *Compresión* sin índices; Apache Hive, en cambio, completó el 100 % de las ejecuciones, sin un solo *timeout*. El contraste entre ambos motores no obedece a un peor diseño de MongoDB, sino a la naturaleza de las consultas más pesadas —las de barrido completo sin índices—: en ausencia de estructuras de acceso, esas consultas agotan el *timeout* en MongoDB, mientras que el modelo de ejecución de Hive sobre HDFS las resuelve dentro del límite de tres horas.

En **MongoDB** la indexación resultó determinante (Tabla 5). Sin índices, 16 de 22 consultas alcanzaron el *timeout* en modalidad distribuida, con una energía mediana de 107.131 J; la incorporación de índices eliminó los *timeouts* y redujo la energía mediana a 1.731 J, una disminución del 98,4 %. Un hallazgo contraintuitivo es que, en modalidad centralizada, la compresión Snappy sin índices fue contraproducente: generó la mayor energía mediana del experimento (60.971 J), porque en un nodo único el CPU descomprime de forma continua sin que la lectura paralela compense ese costo.

Tabla 5: Medianas de tiempo (s) y energía (J) por configuración y modalidad —MongoDB († = *timeout*; **negrita** = óptimo por criterio)

Despliegue	Configuración	Mediana tiempo (s)	Mediana energía (J)
Clúster <i>sharded</i>	Baseline	10.800,0 †	107.130,9
Clúster <i>sharded</i>	Índices	171,7	1.730,8
Clúster <i>sharded</i>	Compresión	693,1	6.879,1
Clúster <i>sharded</i>	Índices+Compresión	171,9	1.755,9
Centralizado	Baseline	10.800,0 †	26.466,7
Centralizado	Índices	242,3	392,2
Centralizado	Compresión	10.800,0 †	60.970,7
Centralizado	Índices+Compresión	163,4	450,7

En **Apache Hive** el patrón se invierte (Tabla 6): la estrategia más eficiente fue la compresión ORC con Snappy, que alcanzó la menor energía mediana en modalidad distribuida (2.145 J), una reducción del 50,3 % frente al *baseline* (4.313 J), mientras que la combinación Índices+Compresión no aportó mejora adicional significativa. Como el *baseline* de Hive emplea formato TextFile plano, esta reducción refleja el efecto conjunto del formato columnar ORC y la compresión Snappy. El comportamiento se mantiene en modalidad centralizada (2.033 J con compresión), confirmando que en Hive la compresión es la palanca de eficiencia dominante, en claro contraste con MongoDB.

4.2. Visualización de resultados

Las medianas de las Tablas 5 y 6 resumen el resultado principal; para respaldarlas con el detalle por consulta, el Anexo G reúne el conjunto completo de figuras, que conviene leer en

Tabla 6: Medianas de tiempo (s) y energía (J) por configuración y modalidad —Apache Hive (**negrita** = óptimo por criterio)

Despliegue	Configuración	Mediana tiempo (s)	Mediana energía (J)
Clúster fragmentado	Baseline	183,9	4.312,7
Clúster fragmentado	Índices	170,5	3.149,7
Clúster fragmentado	Compresión	158,6	2.145,4
Clúster fragmentado	Índices+Compresión	158,5	2.325,9
Centralizado	Baseline	226,7	4.285,8
Centralizado	Índices	194,9	3.196,4
Centralizado	Compresión	183,2	2.032,6
Centralizado	Índices+Compresión	184,8	2.189,6

tres bloques. El *primer bloque* lo forman las barras de energía por consulta y configuración (Figuras G.3 y G.11), que evidencian la magnitud de la reducción energética en cada motor y su distribución a lo largo de las 22 consultas. El *segundo bloque* son los mapas de calor del experimento completo (Figura G.19 y siguiente), que ofrecen la vista global: el *baseline* de MongoDB distribuido está dominado por celdas de *timeout*, mientras que las configuraciones con índices de MongoDB y todas las de Hive operan en un rango estrecho y predecible; ambos mapas comparten la misma escala de color entre motores y modalidades, de modo que las magnitudes son directamente comparables celda a celda. El *tercer bloque* es la comparación multidimensional (Figura G.21), que confirma que las configuraciones de Índices en MongoDB —especialmente centralizado— y de Compresión en Hive son las que más se expanden hacia la eficiencia. Esta organización mantiene el cuerpo del documento centrado en las medianas y los contrastes de hipótesis, y reserva para el anexo la evidencia granular que los sustenta.

4.3. Interpretación de resultados

La correlación de Spearman entre tiempo y energía fue positiva y significativa en casi todas las configuraciones: muy alta en MongoDB con índices ($\rho > 0,97$) y moderada en Hive (ρ entre 0,36 y 0,80), con la única excepción no significativa del *baseline* distribuido de Hive ($\rho = 0,363$, $p = 0,097$); las tablas completas figuran en el Anexo E. Estos resultados permiten contrastar las hipótesis. La **H1** se valida para Hive —el clúster fue más rápido en las cuatro configuraciones, con razones de 0,81 a 0,88— pero se refuta parcialmente para MongoDB, donde la modalidad centralizada con Índices+Compresión obtuvo la menor latencia (163,4 s). La **H2** se valida parcialmente: el centralizado fue más eficiente con índices en MongoDB (392,2 J frente a 1.730,8 J), pero el comportamiento se invierte con compresión (60.971 J frente a 6.879 J). La **H3** también se valida solo en parte: aunque el diseño físico mejora siempre frente al *baseline*, la configuración óptima en energía *no* fue Índices+Compresión en ningún motor, sino *solo Índices* en MongoDB y *solo Compresión* en Hive, y el grado de mejora difiere drásticamente entre motores (98,4 % frente a 50,3 %).

5. Implantación

5.1. Requerimientos mínimos y recomendados

El entorno se ejecutó sobre hardware de propósito general, con la condición indispensable de que el procesador soporte Intel RAPL, requerido por Scaphandre para la medición a nivel de pro-

ceso. La configuración mínima utilizada fue de tres nodos Intel Core i3-6100 (2c/4t, 3,70 GHz), 12 GB de RAM DDR4 y SSD de 447 GB con Ubuntu 24.04.3 LTS; para factores de escala mayores ($SF \geq 10$) se recomienda procesadores de seis o más núcleos, 32 GB de RAM y SSD NVMe de 1 TB. El detalle de los requerimientos de hardware, software y bibliotecas se presenta en el Anexo D (Tablas D.10, D.11 y D.12).

5.2. Preparación del ambiente

El clúster se organiza en tres capas lógicas. La **capa de infraestructura** establece direcciones IP fijas y acceso SSH sin contraseña entre nodos mediante un par de claves RSA. La **capa de motores** despliega, para MongoDB, el *Config Server*, el enrutador mongos y un *shard* en node1, y sendos *shards* en node2 y node3 (instancia *standalone* en la modalidad centralizada); y, para Hadoop con Hive, el *NameNode*, el *ResourceManager* y *HiveServer2* junto a un *DataNode* en node1, y los otros dos *DataNodes* en node2 y node3 (modo pseudodistribuido de nodo único en la centralizada). La **capa de monitoreo** ejecuta Scaphandre 2.6.0 como servicio *systemd* en los tres nodos, con captura continua vía Intel RAPL.

5.3. Evidencia de preparación del ambiente

La correcta preparación se verifica con tres comprobaciones: para HDFS, `hdfs dfsadmin -report` debe reportar los tres *DataNodes* activos con más de 100 GB disponibles por nodo; para MongoDB, `mongo --eval "sh.status()"` debe mostrar las seis colecciones distribuidas y los tres *shards* en estado *primary/secondary*; y para la instrumentación, la lectura de Intel RAPL en reposo debe arrojar valores estables de entre 8 y 12 W por nodo.

5.4. Documentación y manual de usuario

La ejecución se orquesta mediante un script parametrizable, por ejemplo `bash run_experiment.sh --motor mongo --despliegue cluster --config indices --iteraciones 10`, que lanza cada consulta, registra la potencia y exporta los resultados en CSV. Estos se procesan con cuadernos de Jupyter organizados en una jerarquía de cuatro niveles (motor → despliegue → configuración → consulta), estructurando las 3.520 ejecuciones. El código de despliegue, los datos brutos y los cuadernos de análisis se encuentran en repositorios públicos de GitHub (Anexo B), lo que permite la replicación íntegra del estudio.

6. Conclusiones

6.1. Éxitos conseguidos

Los cuatro objetivos específicos se cumplieron. Se compararon ambos motores sobre las 22 consultas TPC-H en las cuatro configuraciones y las dos modalidades (O1); se validó la viabilidad de Scaphandre como instrumento a nivel de proceso en un clúster físico, con correlaciones de Spearman significativas (hasta $\rho > 0,97$ en MongoDB) (O2); se cuantificó el efecto del diseño físico, con reducciones de energía mediana del 98,4 % por indexación en MongoDB y del 50,3 % por compresión en Hive (O3); y se determinaron los *trade-offs* entre paradigmas y modalidades, formulando directrices diferenciadas por motor (O4).

6.2. Avances en el área

El estudio cubre los cuatro vacíos metodológicos identificados: aporta la primera comparación cruzada directa entre MongoDB (*sharding* hash) y Apache Hive (ORC con *bucketing*) bajo TPC-H; la primera evaluación conjunta de las modalidades distribuida y centralizada para ambos motores sobre un mismo hardware; la primera aplicación de Scaphandre a nivel de proceso en un clúster físico multinodo de bases de datos; y la documentación de una infraestructura física reproducible y de bajo costo. El hallazgo transversal es que las recomendaciones de diseño físico son opuestas y no transferibles entre motores —indexación en MongoDB, compresión columnar en Hive—, y que el diseño físico tiene un impacto energético comparable o superior al de la propia topología de despliegue.

6.3. Problemas, riesgos y limitaciones

La limitación más relevante es el factor de escala: el experimento se ejecutó con SF=5, inferior a los tamaños de producción, debido a que el hardware universitario (12 GB de RAM por nodo) no soportó factores mayores en MongoDB sin provocar caídas del clúster; en consecuencia, la magnitud de las reducciones podría no extrapolarse directamente a servidores de mayor capacidad. Además, la validez de constructo de la medición está acotada por Intel RAPL, que atribuye al proceso el consumo de CPU y memoria pero no contabiliza por completo la energía de disco ni de red; el cambio de formato en el *baseline* de Hive (TextFile frente a ORC) implica que las reducciones por compresión reflejan el efecto conjunto de ORC y Snappy; y el análisis, basado en la mediana de diez iteraciones, no modela el calentamiento térmico progresivo del hardware.

6.4. Oportunidades y trabajo futuro

Se identifican cuatro líneas prioritarias: (1) escalar a SF=50 o SF=100 sobre hardware de mayor capacidad para verificar si las reducciones energéticas se mantienen con mayores volúmenes; (2) extender la comparativa a otros motores relacionales y NoSQL bajo la misma metodología; (3) evaluar el modelo de documentos embebidos como alternativa al de referencias en MongoDB, motivado por el desequilibrio de carga observado en el *shard* primario; y (4) replicar el diseño con un benchmark transaccional como YCSB [30] para determinar si las diferencias energéticas son intrínsecas a cada motor o dependen del tipo de carga. En síntesis, la sostenibilidad energética en bases de datos distribuidas no es una propiedad del despliegue en sí mismo, sino del diseño físico aplicado sobre él.

Agradecimientos

Agradecemos a la Escuela de Ingeniería Informática de la Universidad de Valparaíso por las facilidades computacionales e infraestructura proporcionadas para el desarrollo de este estudio. Reconocemos especialmente el aporte de las comunidades de software libre de MongoDB, Apache Hadoop, Apache Hive y Scaphandre, cuyas herramientas y documentación técnica fueron fundamentales para la implementación del entorno experimental y la reproducibilidad de los resultados. Asimismo, se agradece el apoyo académico y metodológico brindado durante el desarrollo del proyecto de seminario. Este proyecto fue financiado por la ANID, Fondecyt Regular N° 1250344.

Aspectos éticos

Este estudio se adhiere a los principios de ética en investigación de la Escuela de Ingeniería Informática. No involucra datos personales ni datos sensibles de sujetos humanos, ya que todas las pruebas fueron realizadas sobre datos sintéticos generados mediante el benchmark TPC-H. Todos los experimentos fueron conducidos en un entorno controlado y reproducible, sin afectar servicios externos ni infraestructura de terceros.

Los autores declaran que este trabajo es original y no plagia material previo; toda fuente bibliográfica, herramienta y contribución externa utilizada ha sido debidamente citada y referenciada. Con el fin de fomentar la transparencia científica y la reproducibilidad, el código fuente, los scripts de automatización, las configuraciones y los cuadernos de análisis fueron publicados en repositorios públicos del proyecto (Anexo B).

Declaración de autoría

El estudiante autor principal desarrolló la totalidad de la implementación técnica del proyecto, incluyendo la configuración del clúster físico, el despliegue de MongoDB y Apache Hive, la integración de Scaphandre, la automatización experimental, la recolección de datos, el procesamiento estadístico y la generación de visualizaciones. Asimismo, realizó la redacción principal del manuscrito y la interpretación de resultados.

Las profesoras guía y correferente participaron en la supervisión metodológica y científica del estudio, aportando revisión crítica, orientación en el diseño experimental y validación de la coherencia académica del trabajo. Todos los autores revisaron y aprobaron la versión final del manuscrito.

Declaración de intereses

Los autores declaran no tener conflictos de interés financieros, académicos, institucionales ni personales que puedan haber influido en el diseño, ejecución, análisis o publicación de este estudio. El trabajo fue desarrollado exclusivamente con fines académicos y de investigación científica.

Referencias

- [1] Wikipedia, Base de datos distribuida (2025).
URL https://es.wikipedia.org/wiki/Base_de_datos_distribuida
- [2] Amazon Web Services (AWS), ¿qué es una base de datos nosql? (2025).
URL <https://aws.amazon.com/es/nosql/>
- [3] MongoDB, Inc., ¿qué es mongodb? (2025).
URL <https://www.mongodb.com/es/company/what-is-mongodb>
- [4] The Apache Software Foundation, Apache hive (2025).
URL <https://hive.apache.org/>

- [5] International Energy Agency, Data centre energy use: Critical review of models and results, Technical Report IEA-4E-TCO-2025-01, IEA 4E Technology Collaboration Programme (2025).
URL <https://www.iea-4e.org/wp-content/uploads/2025/05/Data-Centre-Energy-Use-Critical-Review-of-Models-and-Results.pdf>
- [6] International Energy Agency, Energy and ai: energy demand from ai and data centre electricity use projections to 2030 (2025).
URL <https://www.iea.org/reports/energy-and-ai/energy-demand-from-ai>
- [7] Repsol, Consumo energético (2025).
URL <https://www.repsol.com/es/energia-avanzar/energia/consumo-energetico/index.cshtml>
- [8] Transaction Processing Performance Council (TPC), Tpc benchmark h (tpc-h) (2025).
URL <https://www.tpc.org/tpch/default5.asp>
- [9] Hubblo, How scaphandre computes per process power consumption (2025).
URL <https://hubblo-org.github.io/scaphandre-documentation/explanations/how-scaph-computes-per-process-power-consumption.html>
- [10] Hubblo, Scaphandre documentation, <https://hubblo-org.github.io/scaphandre-documentation/> (2025).
- [11] Green Compute UK, Rapl (running average power limit) (2024).
URL <https://greencompute.uk/Masurement/RAPL>
- [12] A. Thusoo, J. S. Sarma, N. Jain, Z. Shao, P. Chakka, S. Anthony, H. Liu, P. Wyckoff, R. Murthy, Hive: a warehousing solution over a map-reduce framework, Proceedings of the VLDB Endowment 2 (2) (2009) 1626–1629.
- [13] The Apache Software Foundation, Apache hadoop (2025).
URL <https://hadoop.apache.org/>
- [14] Wikipedia, Optimización de consultas (2020).
URL https://es.wikipedia.org/wiki/Optimizaci%C3%B3n_de_consultas
- [15] B. Figueiredo, J. Bernardino, Energy efficiency analysis of query optimizations on MongoDB and Cassandra, in: 12th Iberian Conference on Information Systems and Technologies (CISTI), IEEE, 2017.
- [16] D. Mahajan, C. Blakeney, Z. Zong, Improving the energy efficiency of relational and nosql databases via query optimizations, Sustainable Computing: Informatics and Systems 22 (2019) 120–133. doi:10.1016/j.suscom.2019.01.003.
- [17] C. Gomes, E. Tavares, M. N. Junior, Energy consumption evaluation of nosql dbmss, in: Anais do XV Workshop em Desempenho de Sistemas Computacionais e de Comunicação (WPerformance), 2016, pp. 71–81. doi:10.5753/wperformance.2016.9729.

- [18] H. S. Lella, R. Chattaraj, S. Chimalakonda, K. Manasa, Towards comprehending energy consumption of database management systems - a tool and empirical study, in: 28th International Conference on Evaluation and Assessment in Software Engineering (EASE 2024), ACM, 2024, pp. 691–700. doi:10.1145/3661167.3661174.
- [19] Y. Mansouri, V. Prokhorenko, F. Ullah, M. A. Babar, Resource utilization of distributed databases in edge–cloud environment, IEEE Internet of Things Journal 10 (11) (2023) 9423–9437. doi:10.1109/JIOT.2023.3234955.
- [20] A. Das, B. SNV, N. S. Reddy, P. H. L., Energy efficiency for HDFS, in: 2020 IEEE International Conference on Cloud Computing in Emerging Markets (CCEM), 2020, pp. 9–15. doi:10.1109/CCEM50674.2020.00014.
- [21] J. Conejero, O. Rana, P. Burnap, J. Morgan, B. Caminero, C. Carrión, Analyzing hadoop power consumption and impact on application qos, Future Generation Computer Systems 55 (2016) 213–223. doi:10.1016/j.future.2015.03.009.
- [22] I. Polato, D. Barbosa, A. Hindle, F. Kon, Hadoop energy consumption reduction with hybrid hdfs, in: Proceedings of the 31st Annual ACM Symposium on Applied Computing (SAC), ACM, 2016. doi:10.1145/2851613.2851623.
- [23] E. Cedeno, A. Aguilera, et al., An evaluation of the impact of end-to-end query optimization strategies on energy consumption, in: Proceedings of the 19th International Conference on Evaluation of Novel Approaches to Software Engineering (ENASE 2024), 2024, pp. 657–665.
- [24] R. Niemann, Towards the prediction of the performance and energy efficiency of distributed data management systems, in: Proceedings of the 7th ACM/SPEC International Conference on Performance Engineering Companion (ICPE Companion), 2016.
- [25] V. Prokhorenko, M. A. Babar, Energy efficiency evaluation of local and offloaded data processing, in: Proceedings of the International Conference on Computer Science and Information Technologies (CSIT), 2023.
- [26] H. Ahmed, Bigdata for energy efficiency: Hadoop + hive implementation (2020). URL https://github.com/hussnainahmed/BigData_for_Energy_Efficiency
- [27] L. F. da Silva, J. V. F. Lima, An evaluation of relational and nosql distributed databases on a low-power cluster, The Journal of Supercomputing 79 (2023) 12155–12178. doi:10.1007/s11227-023-05166-7.
- [28] A. Karras, C. Karras, A. Pervanas, S. Sioutas, C. Zaroliagis, Sql query optimization in distributed nosql databases for cloud-based applications, in: Algorithmic Aspects of Cloud Computing, ALGO CLOUD 2022, Lecture Notes in Computer Science, Vol. 13799, Springer, 2023, pp. 21–41. doi:10.1007/978-3-031-33437-5_2.
- [29] M. Shah, A. Kothari, S. Patel, A comprehensive survey on energy consumption analysis for nosql, Scalable Computing: Practice and Experience 23 (1) (2022). doi:10.12694/scpe.v23i1.1971.
- [30] Benchant, Database benchmarking: Evaluating database performance effectively (2024). URL <https://benchant.com/blog/database-benchmarking>

Anexos

Este apartado reúne el material complementario del estudio: el glosario de siglas, la disponibilidad de recursos, la síntesis completa del estado del arte, los requerimientos de implementación, los resultados estadísticos detallados, las tablas de resultados por consulta y las figuras complementarias no incluidas en el cuerpo del artículo.

Anexo A. Glosario de siglas

La Tabla A.7 reúne, en orden alfabético, las siglas y abreviaturas técnicas empleadas a lo largo del documento junto con su desarrollo y una breve descripción.

Tabla A.7: Glosario de siglas y abreviaturas empleadas en el documento

Sigla	Significado
BSON	<i>Binary JSON</i> ; formato binario de documentos utilizado por MongoDB.
CBO	<i>Cost-Based Optimizer</i> ; optimizador de consultas basado en costos.
CPU	<i>Central Processing Unit</i> ; unidad central de procesamiento.
CSV	<i>Comma-Separated Values</i> ; valores separados por comas.
DDR4	<i>Double Data Rate 4</i> ; generación de memoria RAM.
Gbps	<i>Gigabits per second</i> ; gigabits por segundo.
GB	<i>Gigabyte</i> ; unidad de almacenamiento.
GHz	Gigahercio; unidad de frecuencia de reloj.
HDFS	<i>Hadoop Distributed File System</i> ; sistema de archivos distribuido de Hadoop.
IA	Inteligencia Artificial.
IP	<i>Internet Protocol</i> ; protocolo de red.
J	<i>Joule</i> (julio); unidad de energía.
JDK	<i>Java Development Kit</i> ; kit de desarrollo de Java (OpenJDK).
LTS	<i>Long-Term Support</i> ; versiones con soporte extendido (Ubuntu).
Mbps	<i>Megabits per second</i> ; megabits por segundo.
NoSQL	<i>Not only SQL</i> ; familia de bases de datos no relacionales.
NVMe	<i>Non-Volatile Memory express</i> ; interfaz de almacenamiento SSD de alta velocidad.
ORC	<i>Optimized Row Columnar</i> ; formato de almacenamiento columnar de Apache Hive.
PID	<i>Process Identifier</i> ; identificador de proceso del sistema operativo.
PMC	<i>Performance Monitoring Counters</i> ; contadores de monitoreo de rendimiento del procesador.
RAM	<i>Random Access Memory</i> ; memoria de acceso aleatorio.
RAPL	<i>Running Average Power Limit</i> ; interfaz de Intel para estimar el consumo energético.
RPi	<i>Raspberry Pi</i> ; computador de placa única.
RSA	<i>Rivest–Shamir–Adleman</i> ; algoritmo de criptografía de clave pública.
SF	<i>Scale Factor</i> ; factor de escala del <i>benchmark</i> TPC-H.
SGBD	Sistema Gestor de Bases de Datos.
SQL	<i>Structured Query Language</i> ; lenguaje de consulta estructurado.
SSD	<i>Solid-State Drive</i> ; unidad de estado sólido.
SSH	<i>Secure Shell</i> ; protocolo de acceso remoto seguro.

continúa en la página siguiente

Tabla A.7 — continuación

Sigla	Significado
TB	<i>Terabyte</i> ; unidad de almacenamiento.
TPC	<i>Transaction Processing Performance Council</i> ; organismo que define los <i>benchmarks</i> TPC.
TPC-DS	<i>TPC Benchmark DS</i> ; <i>benchmark</i> de soporte a decisiones.
TPC-H	<i>TPC Benchmark H</i> ; <i>benchmark</i> de soporte a decisiones (22 consultas <i>ad-hoc</i>).
TWh	Teravatio-hora; unidad de energía a gran escala.
W	<i>Watt</i> (vatio); unidad de potencia.
YARN	<i>Yet Another Resource Negotiator</i> ; gestor de recursos de Hadoop.
YCSB	<i>Yahoo! Cloud Serving Benchmark</i> ; <i>benchmark</i> para bases de datos NoSQL.

Anexo B. Disponibilidad de recursos

Los datos brutos generados por Scaphandre y los cuadernos de análisis se encuentran en repositorios públicos de GitHub, organizados por motor y modalidad de despliegue.

Tabla B.8: Repositorios públicos con los datos brutos y el código del experimento

Motor	Modalidad	Repositorio
MongoDB 8.0.17	Centralizado	github.com/Carrillo-Ch12/Mongo_centralizado_5G
MongoDB 8.0.17	Distribuido	github.com/Carrillo-Ch12/Metricas_5g
Apache Hive 3.1.3	Centralizado	github.com/Carrillo-Ch12/5g_hive_centralizado
Apache Hive 3.1.3	Distribuido	github.com/Carrillo-Ch12/Hive_metricas_new_5G
Análisis (notebooks)	—	github.com/Carrillo-Ch12/Energy_consumption_analysis
Entorno (despliegue)	—	github.com/Carrillo-Ch12/-Mongo-Hive-Environment

Anexo C. Síntesis completa del estado del arte

La Tabla C.9 sintetiza los catorce trabajos revisados en cuanto a tecnologías evaluadas, modalidad de despliegue, benchmark, tipo de medición energética y herramienta de medición, y los contrasta con el presente estudio (última fila).

Tabla C.9: Síntesis comparativa de los 14 trabajos del estado del arte y contraste con este estudio

ID	Trabajo	Tecnologías	Despliegue	Bench.	Medición	Herramienta
1	Mahajan et al.	MongoDB, Cassandra, MySQL, PostgreSQL	Centralizado (1 nodo)	YCSB	Energía y potencia	Medidor externo
2	Gomes et al.	MongoDB, Cassandra, OrientDB	Centralizado (1 nodo)	YCSB	Potencia (W)	Medidor externo
3	Conejero et al.	Apache Hadoop (HDFS + MapReduce)	Clúster Hadoop	TPC-H	Potencia (W)	Medidor hardware
4	Lella et al.	MongoDB, MySQL, PostgreSQL, Cassandra	Centralizado (1 nodo)	TPC-DS	Energía (J)	DBJoules
5	Polato et al.	Apache Hadoop con HDFS híbrido	Clúster Hadoop	TPC-DS	Energía (J)	Medidor hardware
6	Cedeño et al.	PostgreSQL distribuido	Clúster distribuido	TPC-H	Energía (J)	Juliet (RAPL)
7	Figueiredo y Bernardino	MongoDB, Cassandra	Centralizado (1 nodo)	YCSB	Energía y potencia	Scaphandre
8	Ahmed	Apache Hadoop + Hive	Clúster Hadoop	TPC-DS	—	—
9	Mansouri et al.	MongoDB, Cassandra, Redis, MySQL	Edge-Cloud (RPi+Azure)	YCSB	Energía (J)	Intel RAPL agregado
10	Das et al.	HDFS (Hadoop)	Clúster Hadoop	TPC-H	Energía (J)	Medidor externo + PMC
11	Karras et al.	MongoDB + Apache Spark SQL	Clúster distribuido	TPC-H	—	—
12	Silva y Lima	MongoDB, Cassandra, MariaDB, Redis	Clúster bajo consumo (RPi 3)	YCSB	—	—
13	Niemann	Cassandra, MongoDB	Clúster distribuido	TPC-DS	Energía y potencia	Medidor externo
14	Prokhorenko y Babar	MongoDB, Cassandra, Redis, MySQL	Local + remoto (offloading)	YCSB	Energía y potencia	Intel RAPL agregado
Este estudio: MongoDB 8.0.17 y Apache Hive 3.1.3 Clúster 3 nodos + Centralizado TPC-H Energía y potencia Índices + Snappy + ORC + bucketing/sharding hash Scaphandre 2.6.0 multinodo (proceso, vía Intel RAPL)						

“—” = dimensión no reportada o no aplicable. “Medidor externo” = dispositivos hardware que miden el servidor completo sin granularidad por proceso. “PMC” = Performance Monitoring Counters.

Anexo D. Requerimientos de implementación

La replicación del entorno exige que el procesador soporte Intel RAPL, condición necesaria para la medición proceso-nivel de Scaphandre.

Tabla D.10: Requerimientos de hardware por nodo (mínimo y recomendado)

Componente	Mínimo (SF=5, este estudio)	Recomendado (SF≥10)
Procesador	Intel Core i3-6100, 2c/4t, 3,70 GHz	Intel Core i5/i7, 6c+, 3,50 GHz
Memoria RAM	12 GB DDR4	32 GB DDR4 o superior
Almacenamiento	SSD Kingston 447 GB	SSD NVMe 1 TB
Red	Ethernet 100 Mbps, IP fija	Ethernet Gigabit (1 Gbps), IP fija
Sistema operativo	Ubuntu 24.04.3 LTS (64-bit)	Ubuntu 22.04/24.04 LTS (64-bit)

Tabla D.11: Requerimientos de software por nodo

Componente	Versión	Propósito
MongoDB	8.0.17	Motor NoSQL documental
Apache Hadoop	3.3.6	HDFS y YARN
Apache Hive	3.1.3	Data warehouse sobre Hadoop
Scaphandre	2.6.0	Medición energética RAPL proceso-nivel
Python	3.10+	Orquestación y análisis
Java (OpenJDK)	11	Requisito de Hadoop y Hive
TPC-H dbgen	2.18.0	Generación de datos sintéticos

Tabla D.12: Bibliotecas de Python utilizadas en el análisis

Biblioteca	Uso principal
pymongo / pyhive	Conexión con MongoDB / Hive
pandas / numpy	Manipulación de datos y cálculo numérico
scipy.stats	Pruebas estadísticas (Wilcoxon, Spearman)
matplotlib / seaborn	Visualizaciones estadísticas

Anexo E. Resultados estadísticos detallados

Tabla E.13: Correlación de Spearman entre tiempo de ejecución y energía —MongoDB

Despliegue	Configuración	ρ	p -valor
Distribuido	Baseline	0,632	0,002
Distribuido	Índices	0,974	$2,3 \times 10^{-14}$
Distribuido	Compresión	0,984	$1,7 \times 10^{-16}$
Distribuido	Índices+Compresión	0,980	$2,0 \times 10^{-15}$
Centralizado	Baseline	0,673	0,001
Centralizado	Índices	0,886	$4,2 \times 10^{-8}$
Centralizado	Compresión	0,673	0,001
Centralizado	Índices+Compresión	0,967	$2,2 \times 10^{-13}$

Tabla E.14: Correlación de Spearman entre tiempo de ejecución y energía —Apache Hive

Despliegue	Configuración	ρ	p -valor
Distribuido	Baseline	0,363	0,097
Distribuido	Índices	0,513	0,015
Distribuido	Compresión	0,710	$2,2 \times 10^{-4}$
Distribuido	Índices+Compresión	0,617	0,002
Centralizado	Baseline	0,804	$7,0 \times 10^{-6}$
Centralizado	Índices	0,753	$5,3 \times 10^{-5}$
Centralizado	Compresión	0,637	0,001
Centralizado	Índices+Compresión	0,651	0,001

Tabla E.15: Ranking de configuraciones por *score* total de Wilcoxon con corrección Holm–Bonferroni ($\alpha = 0,05$)

MongoDB				Apache Hive			
Config.	T	E	Total	Config.	T	E	Total
Cent. Índices+Comp.	4	5	9	Frag. Compresión	6	4	10
Cent. Índices	2	7	9	Frag. Índices+Comp.	6	4	10
Clúster Índices	3	2	5	Cent. Compresión	0	5	5
Clúster Índices+Comp.	3	0	3	Cent. Índices+Comp.	0	3	3
Clúster Compresión	3	-2	1	Frag. Índices	1	-2	-1
Cent. Compresión	-5	-3	-8	Frag. Baseline	-1	-6	-7
Cent. Baseline	-5	-3	-8	Cent. Índices	-5	-2	-7
Clúster Baseline	-5	-6	-11	Cent. Baseline	-7	-6	-13

Anexo F. Resultados detallados por consulta TPC-H

Las tablas siguientes reportan el tiempo (T, en horas) y la energía (E, en joules) promedio por consulta. El símbolo † indica *timeout* a las 3 horas.

Tabla F.16: Resultados por consulta —MongoDB clúster *sharded*

Q	Baseline		Índices		Compresión		Índ.+Comp.	
	T(h)	E(J)	T(h)	E(J)	T(h)	E(J)	T(h)	E(J)
1	0,007	372,7	0,021	982,4	0,008	380,3	0,013	680,0
2	0,819	23.178,3	0,008	100,7	0,007	96,6	0,008	100,0
3	3,00†	246.494,2	0,093	5.979,7	3,00†	795.315,2	0,094	6.065,0
4	3,00†	212.453,6	0,007	322,7	0,007	318,0	0,008	332,2
5	3,00†	105.383,4	0,393	14.678,0	0,387	14.278,0	0,396	14.740,2
6	0,001	62,2	0,000	0,6	0,003	74,1	0,000	0,7
7	3,00†	108.878,3	2,205	75.568,8	2,138	74.471,7	2,197	76.033,9
8	3,00†	146.181,8	0,955	13.213,2	0,917	12.737,1	0,965	13.292,2
9	3,00†	165.703,2	0,764	14.906,0	3,00†	780.251,3	0,756	15.009,2
10	3,00†	145.042,1	0,057	2.086,8	0,057	2.046,2	0,058	2.076,2
11	2,94†	147.701,7	0,306	10.799,6	0,307	10.645,9	0,307	10.820,2
12	3,00†	99.580,1	0,009	107,7	0,008	167,7	0,008	124,9
13	3,00†	661.798,3	0,153	17.636,2	3,00†	790.762,3	0,153	17.780,0
14	3,00†	86.542,3	0,025	891,9	0,027	979,4	0,025	896,9
15	0,003	73,7	0,002	13,4	0,002	67,0	0,001	12,7
16	3,00†	98.306,0	0,042	1.510,4	0,041	1.500,5	0,041	1.522,7
17	0,554	141.284,1	0,000	1,9	0,554	141.739,1	0,000	2,0
18	0,101	1.514,1	0,016	499,0	0,014	549,7	0,014	505,9
19	3,00†	85.081,0	0,071	2.599,9	0,078	3.112,3	0,072	2.647,6
20	3,00†	803.157,8	0,016	1.564,1	3,00†	410.826,0	0,016	1.584,2
21	3,00†	184.973,8	1,454	53.360,3	1,373	51.772,5	1,449	53.680,0
22	3,00†	87.696,1	0,054	1.897,5	3,00†	174.205,6	0,054	1.927,7

Tabla F.17: Resultados por consulta —MongoDB centralizado

Q	Baseline		Índices		Compresión		Índ.+Comp.	
	T(h)	E(J)	T(h)	E(J)	T(h)	E(J)	T(h)	E(J)
1	0,034	295,8	1,895	4.019,8	0,023	309,3	0,427	8.420,1
2	3,00†	61.495,6	0,004	30,9	3,00†	60.993,0	0,004	33,4
3	3,00†	18.701,4	0,067	642,6	3,00†	62.273,1	0,060	674,7
4	3,00†	17.494,9	0,068	389,6	3,00†	62.489,8	0,045	364,1
5	3,00†	13.696,6	0,311	2.645,3	3,00†	63.155,1	0,179	2.628,9
6	0,025	110,6	0,049	86,5	0,014	124,4	0,028	119,8
7	3,00†	62.870,1	1,465	11.208,5	3,00†	62.191,9	0,759	13.031,3
8	3,00†	14.463,7	0,303	3.803,3	3,00†	62.838,7	0,250	3.807,2
9	3,00†	34.232,1	0,474	2.981,1	3,00†	60.948,4	0,225	3.380,1
10	3,00†	16.352,7	0,082	676,7	3,00†	61.908,3	0,063	689,3
11	3,00†	59.636,4	0,116	1.928,4	3,00†	59.577,5	0,117	1.955,5
12	3,00†	59.808,8	0,154	372,9	3,00†	58.715,5	0,054	484,6
13	3,00†	59.095,6	0,053	706,5	3,00†	59.071,5	0,046	707,7
14	3,00†	59.451,8	0,048	170,3	3,00†	59.185,8	0,034	222,4
15	0,024	109,5	0,082	165,9	0,013	122,9	0,039	315,1
16	3,00†	59.114,9	0,023	224,3	3,00†	59.328,5	0,017	216,0
17	3,00†	13.445,8	0,006	12,7	3,00†	63.359,9	0,007	21,1
18	0,271	4.873,9	0,037	336,6	0,254	4.916,9	0,025	356,3
19	3,00†	59.440,0	0,043	394,8	3,00†	59.497,0	0,030	416,7
20	3,00†	16.050,0	0,020	112,8	3,00†	62.550,4	0,019	121,2
21	3,00†	45.084,4	0,880	14.858,4	3,00†	61.605,0	0,881	14.981,1
22	3,00†	62.560,7	0,008	66,2	3,00†	61.765,7	0,006	63,1

Tabla F.18: Resultados por consulta —Apache Hive clúster fragmentado (sin *timeouts*)

Q	Baseline		Índices		Compresión		Índ.+Comp.	
	T(h)	E(J)	T(h)	E(J)	T(h)	E(J)	T(h)	E(J)
1	0,025	3.465,6	0,021	1.810,5	0,018	961,9	0,018	938,4
2	0,068	2.630,2	0,067	2.641,6	0,068	2.543,1	0,068	2.502,5
3	0,047	6.042,1	0,041	4.140,3	0,039	2.815,5	0,040	2.942,6
4	0,036	5.567,9	0,031	3.019,3	0,028	2.120,4	0,029	2.149,3
5	0,057	4.205,8	0,057	3.108,6	0,055	2.722,8	0,056	2.611,3
6	0,014	2.073,6	0,011	873,3	0,010	573,4	0,010	554,8
7	0,062	3.877,7	0,059	2.484,0	0,058	2.170,4	0,058	2.139,3
8	0,083	7.539,2	0,082	5.893,2	0,079	4.404,5	0,079	4.777,6
9	0,074	8.294,7	0,073	6.480,6	0,072	4.921,6	0,071	5.235,2
10	0,051	5.516,8	0,047	3.760,6	0,044	2.687,7	0,045	2.783,0
11	0,061	1.949,9	0,060	1.884,1	0,061	1.866,1	0,061	1.764,1
12	0,036	5.077,6	0,032	3.190,9	0,028	2.103,3	0,028	2.130,8
13	0,050	3.754,0	0,051	3.752,6	0,054	3.785,3	0,050	3.545,0
14	0,027	4.191,7	0,023	2.569,5	0,020	1.572,8	0,020	1.668,3
15	0,059	7.155,5	0,050	3.738,9	0,045	2.106,2	0,045	2.122,4
16	0,053	2.135,6	0,041	1.829,8	0,053	1.992,4	0,042	1.620,7
17	0,052	10.389,9	0,048	7.259,1	0,043	4.656,4	0,044	4.885,6
18	0,039	4.419,7	0,044	6.755,7	0,034	2.074,1	0,042	6.343,7
19	0,026	3.932,8	0,023	2.549,1	0,020	1.615,1	0,020	1.690,6
20	0,061	5.392,2	0,057	3.557,8	0,054	2.514,2	0,054	2.563,2
21	0,114	17.161,9	0,101	11.372,8	0,096	7.810,6	0,096	8.278,2
22	0,040	1.830,4	0,039	1.658,1	0,040	1.603,8	0,040	1.602,0

Tabla F.19: Resultados por consulta —Apache Hive centralizado (sin *timeouts*)

Q	Baseline		Índices		Compresión		Índ.+Comp.	
	T(h)	E(J)	T(h)	E(J)	T(h)	E(J)	T(h)	E(J)
1	0,045	3.542,9	0,031	2.050,1	0,024	1.029,9	0,023	1.096,4
2	0,067	1.576,7	0,058	1.343,7	0,067	963,4	0,068	934,0
3	0,060	4.267,4	0,044	2.475,1	0,040	1.628,7	0,038	1.680,5
4	0,064	5.296,2	0,045	3.270,4	0,036	2.195,6	0,036	2.273,0
5	0,073	4.304,9	0,061	3.140,3	0,055	2.419,6	0,054	2.404,7
6	0,027	2.017,7	0,017	910,8	0,013	502,8	0,013	479,0
7	0,070	3.447,6	0,056	2.092,9	0,052	1.561,8	0,052	1.648,8
8	0,109	7.021,9	0,093	5.417,7	0,083	4.222,2	0,083	4.471,5
9	0,109	8.527,9	0,094	6.686,8	0,084	5.157,7	0,084	5.225,1
10	0,073	5.007,3	0,060	3.770,5	0,049	2.551,6	0,051	2.715,2
11	0,057	1.504,8	0,053	1.377,6	0,052	1.135,9	0,052	1.143,3
12	0,061	4.844,8	0,047	3.343,1	0,036	2.027,3	0,037	2.143,2
13	0,061	4.155,0	0,069	5.280,7	0,079	4.590,3	0,080	5.208,1
14	0,048	3.976,8	0,035	2.576,0	0,025	1.494,9	0,026	1.574,6
15	0,097	7.404,5	0,069	4.440,6	0,051	2.249,5	0,052	2.447,1
16	0,054	1.772,4	0,052	1.669,8	0,051	1.339,4	0,051	1.415,7
17	0,104	10.380,3	0,084	7.927,2	0,064	5.602,6	0,065	5.814,4
18	0,062	4.304,3	0,050	3.252,4	0,040	2.037,9	0,041	2.235,9
19	0,046	3.663,4	0,036	2.731,2	0,026	1.556,1	0,027	1.662,7
20	0,084	5.324,6	0,067	3.761,7	0,058	2.270,4	0,066	2.477,4
21	0,197	18.145,3	0,153	13.387,7	0,124	10.048,0	0,125	10.137,9
22	0,043	1.720,6	0,040	1.518,3	0,040	1.220,5	0,040	1.205,0

Anexo G. Figuras complementarias

Anexo G.1. Metodología y diseño experimental



Figura G.1: Esquema metodológico del proyecto: desde la generación de datos TPC-H y la preparación de los entornos hasta la ejecución instrumentada y el análisis estadístico.

Modelamiento de la solución

4 configuraciones x 2 motores x 2 distribuciones x 22 consultas x 10 iteraciones = 3520 ejecuciones




Figura G.2: Diseño de experimentos: flujo de fases desde la generación de datos hasta el análisis.

Anexo G.2. MongoDB




Figura G.3: Energía consumida (J) por consulta y configuración —MongoDB clúster *sharded* (escala logarítmica). La indexación reduce el consumo en casi dos órdenes de magnitud frente al *baseline*.




Figura G.4: Tiempo de ejecución (s) por consulta y configuración —MongoDB clúster *sharded* (escala logarítmica; línea roja = *timeout* de 10.800 s).




Figura G.5: Tiempo de ejecución (s) por consulta y configuración —MongoDB centralizado (escala logarítmica).




Figura G.6: Energía consumida (J) por consulta y configuración —MongoDB centralizado (escala logarítmica).




Figura G.7: Comparación de medianas de tiempo y energía entre las modalidades distribuida y centralizada —MongoDB.




Figura G.8: Relación tiempo–energía (escala log–log) por configuración y modalidad —MongoDB. Se presenta en la misma escala que la figura equivalente de Hive para permitir la comparación directa entre motores.




Figura G.9: Distribución porcentual del tiempo por *shard*—MongoDB clúster *sharded*, configuraciones con índices.




Figura G.10: Radar por consulta (Q1–Q22) del tiempo de ejecución en MongoDB, contrastando *baseline* e Índices (escala logarítmica).

Anexo G.3. Apache Hive




Figura G.11: Energía consumida (J) por consulta y configuración —Apache Hive clúster fragmentado. La compresión ORC+Snappy es la estrategia de menor consumo.




Figura G.12: Tiempo de ejecución (s) por consulta y configuración —Apache Hive clúster fragmentado.




Figura G.13: Tiempo de ejecución (s) por consulta y configuración —Apache Hive centralizado.




Figura G.14: Energía consumida (J) por consulta y configuración —Apache Hive centralizado.




Figura G.15: Comparación de medianas de tiempo y energía entre las modalidades distribuida y centralizada —Apache Hive.




Figura G.16: Relación tiempo–energía (escala log–log) por configuración y modalidad —Apache Hive. Se presenta en la misma escala que la figura equivalente de MongoDB (Figura G.8), lo que evidencia el rango de operación mucho más acotado y predecible de Hive.



Figura G.17: Distribución porcentual del tiempo por nodo —Apache Hive clúster fragmentado, configuraciones con índices.




Figura G.18: Radar por consulta (Q1–Q22) del tiempo de ejecución en Apache Hive, contrastando *baseline* y Compresión (escala lineal).

Anexo G.4. Análisis global




Figura G.19: Mapa de calor del tiempo de ejecución promedio (s) por consulta TPC-H para todos los motores, modalidades y configuraciones, en una escala de color unificada que permite la comparación directa celda a celda. Las celdas T/O corresponden a *timeouts*.




Figura G.20: Mapa de calor del consumo energético promedio (J) por consulta TPC-H para todos los motores, modalidades y configuraciones, en una escala de color unificada que permite la comparación directa celda a celda.




Figura G.21: Comparación multidimensional de rendimiento y eficiencia energética para todas las configuraciones evaluadas en MongoDB y Apache Hive, en modalidades distribuida y centralizada.